TCC I × TCC II: dados e resultados

Comparação entre o dataset e os resultados do TCC I e a primeira rodada do TCC II (mesma pipeline e mesmos grids de hiperparâmetros do TCC I). Rodada de 20/10/2026.

1. Proteínas em cada grupo

Conjunto	TCC I	TCC II
Fonte das positivas	Tsoi et al. (2012) — 21 loci	Dand et al. (2025) — loci estabelecidos (“Known”)
Positivas (treino)	**28 genes · 111 seqs**	**96 genes · 316 seqs** RUNX3 e CARD14 reservadas para a validação externa
Negativas fáceis (housekeeping)	18 genes · 72 seqs	34 genes · 106 seqs
Negativas intermediárias (outras doenças imunes)	7 genes · 20 seqs Crohn e artrite reumatoide	35 genes · 105 seqs 13 doenças imunomediadas
Negativas difíceis (imunes não ligadas e parálogos)	5 genes · 20 seqs só imunes não ligadas	42 genes · 105 seqs imunes não ligadas + parálogos dos marcadores
Negativas (treino)	**30 genes · 112 seqs**	**111 genes · 316 seqs**
Proporção fácil / interm. / difícil	64% / 18% / 18%	34% / 33% / 33%
Total de treino	**58 genes · 223 seqs**	**207 genes · 632 seqs**
Validação externa	INS, PTPN22, IL12B, CARD14, RUNX3	as mesmas 5 proteínas
Exclusão de negativas	STAT4 (locus de psoríase)	genes positivos, genes a <250 kb das 109 regiões de Dand (2025) e genes com associação à psoríase (Open Targets, GWAS Catalog, UniProt)

seqs = sequências. No TCC I, os genes de Crohn e artrite reumatoide estavam no grupo “difícil”; aqui foram reagrupados como intermediários para seguir os níveis do TCC II.

2. Resultados da validação cruzada (N = 1000)

Média ± desvio padrão nos 10 folds, em %, para os hiperparâmetros vencedores do GridSearchCV. Em negrito, o melhor modelo de cada dataset por ROC-AUC.

Modelo		Acurácia	Sensibilidade	Especificidade	ROC-AUC	MCC
Regressão Logística	TCC I	**97,4 ± 2,9**	**97,3 ± 5,8**	**97,3 ± 4,1**	**99,8 ± 0,3**	**95,0 ± 5,5**
	TCC II	92,7 ± 4,4	93,1 ± 4,8	92,4 ± 6,4	98,4 ± 1,2	85,7 ± 8,4
SVM	TCC I	95,1 ± 3,1	91,8 ± 7,6	98,2 ± 3,6	99,4 ± 0,7	90,7 ± 5,8
	TCC II	**96,5 ± 2,7**	**97,2 ± 2,6**	**95,9 ± 3,7**	**99,6 ± 0,3**	**93,1 ± 5,4**
Random Forest	TCC I	95,1 ± 2,5	92,8 ± 5,4	97,3 ± 5,8	99,3 ± 1,0	90,6 ± 4,5
	TCC II	91,3 ± 1,1	86,4 ± 3,3	96,2 ± 3,4	97,7 ± 1,0	83,2 ± 2,2
Gradient Boosting	TCC I	87,0 ± 7,9	92,8 ± 6,8	81,2 ± 11,7	95,5 ± 3,1	74,9 ± 15,5
	TCC II	91,0 ± 3,2	91,8 ± 4,3	90,2 ± 3,6	97,8 ± 1,5	82,1 ± 6,3
Naive Bayes	TCC I	72,2 ± 11,4	56,9 ± 17,1	87,3 ± 10,9	78,1 ± 14,8	47,0 ± 22,7
	TCC II	82,0 ± 3,8	82,0 ± 7,6	82,0 ± 9,1	90,7 ± 2,8	64,7 ± 7,5
kNN	TCC I	81,2 ± 5,9	100,0 ± 0,0	62,5 ± 11,7	89,5 ± 5,4	67,5 ± 9,3
	TCC II	82,7 ± 3,7	68,4 ± 8,1	97,2 ± 3,3	94,3 ± 1,7	68,7 ± 6,3

3. ROC-AUC por tamanho do vetor

Média nos 10 folds, em %. Em negrito, o melhor N de cada modelo.

Modelo		N = 300	N = 400	N = 500	N = 1000
Regressão Logística	TCC I	97,6	97,1	98,7	**99,8**
	TCC II	88,9	93,8	95,5	**98,4**
SVM	TCC I	98,5	98,5	99,0	**99,4**
	TCC II	98,4	99,1	99,1	**99,6**
Random Forest	TCC I	98,9	98,1	99,0	**99,3**
	TCC II	96,6	97,5	97,3	**97,7**
Gradient Boosting	TCC I	**96,6**	95,7	96,3	95,5
	TCC II	95,9	96,6	97,1	**97,8**
Naive Bayes	TCC I	73,2	73,5	74,6	**78,1**
	TCC II	83,1	87,2	88,3	**90,7**
kNN	TCC I	89,6	90,1	**91,4**	89,5
	TCC II	94,2	93,4	**94,5**	94,3

4. Validação externa (5 proteínas)

Classificação de cada proteína pelos modelos finais (N = 1000). O percentual é a confiança na classe prevista: "✗ 69,7%" significa que o modelo errou com 69,7% de confiança.

Proteína		Situação no treino	LR	SVM	RF	GB	NB	kNN
INS esperado: negativo	TCC I	negativa treinada	✓ 99,0%	✓ 99,6%	✓ 89,5%	✓ 100,0%	✓ 100,0%	✓ 100,0%
	TCC II	negativa não treinada (excluída pelos critérios v2)	✗ 69,7%	✗ 50,0%	✗ 52,0%	✓ 84,4%	✓ 100,0%	✓ 100,0%
PTPN22 esperado: negativo	TCC I	negativa — apresentada como não treinada, mas a mesma sequência humana estava nos negativos de treino	✓ 93,4%	✓ 99,6%	✓ 84,0%	✓ 100,0%	✓ 100,0%	✓ 66,7%
	TCC II	negativa não treinada	✗ 61,7%	✗ 58,0%	~ 54,0%	✗ 66,9%	✗ 96,8%	✓ 100,0%
IL12B esperado: positivo	TCC I	positiva treinada	✓ 99,7%	✓ 100,0%	✓ 93,5%	✓ 100,0%	✓ 100,0%	✓ 100,0%
	TCC II	positiva treinada	✓ 96,2%	✓ 100,0%	✓ 89,5%	✓ 100,0%	✓ 100,0%	✓ 100,0%
CARD14 esperado: positivo	TCC I	positiva não treinada (epitelial)	✗ 70,5%	✗ 51,2%	~ 52,5%	✗ 91,1%	✗ 100,0%	✓ 100,0%
	TCC II	positiva não treinada (epitelial)	✓ 68,1%	~ 52,9%	✗ 54,5%	✗ 59,3%	✗ 98,4%	✗ 100,0%
RUNX3 esperado: positivo	TCC I	positiva não treinada (imune sistêmica)	✓ 67,6%	✓ 90,3%	✗ 51,0%	✗ 100,0%	✗ 100,0%	✓ 100,0%
	TCC II	positiva não treinada (imune sistêmica)	✗ 88,6%	✗ 76,4%	~ 52,0%	✗ 95,7%	✓ 67,4%	✗ 100,0%

✓ correto · ✗ incorreto · ~ correto, mas com confiança abaixo de 65%.

Apêndice — genes de cada grupo

Grupo	Genes
TCC I — positivas 28 genes	ERAP1, FBXL19, HLA-B, HLA-C, IFIH1, IL12B, IL13, IL23A, IL23R, IL28RA, IL4, KCNH7, LCE3B, LCE3D, NFKBIA, NOS2, PRDX5, PRSS53, REL, RNF114, RPS6KA4, STAT2, TNFAIP3, TNIP1, TRAF3IP2, TYK2, UBE2L3, ZMIZ1
TCC I — negativas fáceis 18 genes	ACTB, ALB, ALDOA, ATP5F1A, CAT, COL1A1, ENO1, GAPDH, HBA1, HBB, INS, LDHA, PGK1, PKM, SOD1, TPI1, TUBB, VIM
TCC I — negativas intermediárias 7 genes	ATG16L1, CTLA4, IRGM, NOD2, PADI4, PTPN22, TRAF1
TCC I — negativas difíceis 5 genes	CD3E, IFNG, IL10, IL2, IL5
TCC II — positivas (treino) 96 genes	ANXA6, AP5B1, B3GNT2, BRAP, C1orf141, C1orf68, CAMK2G, CARD6, CARM1, CCHCR1, CDKAL1, CFL1, CHUK, DDX58, DENND1B, ELMO1, ERAP1, ETS1, EXOC2, FASLG, FBXL19, FIBP, FOSL1, FUBP1, FUT2, HLA-B, HLA-C, HSD3B7, IFIH1, IFNLR1, IKBKE, IKZF3, IL12B, IL13, IL23A, IL23R, IL31, IL4, ILF3, IRF4, KCNH7, KLF13, KLF4, KLLN, KLRC4, KLRK1, KPRP, LCE3A, LCE3B, LCE3C, LCE3D, LNPEP, LRRC7, MAPKAPK5, MBD2, NFKBIA, NFKBIZ, NOS2, PLCL2, POLI, PRDX5, PRM3, PRSS53, PSMA6, PTEN, PTPN2, PTRF, REL, RNF114, RNF145, RPS6KA4, SLC45A1, SNAI1, SOCS1, STARD6, STAT2, STAT3, STAT5A, STAT5B, TAGAP, TNF, TNFAIP3, TNFRSF9, TNFSF15, TNIP1, TP63, TRAF3IP2, TRIM47, TRIM65, TYK2, UBAC2, UBE2L3, YDJC, ZC3H12C, ZMIZ1, ZNF365
TCC II — negativas fáceis (treino) 34 genes	ACOT13, ALB, ALDOA, ANO6, AP1B1, APEX1, CAMTA2, CCDC12, CCDC124, CYB5B, EXOC8, EXT2, GPKOW, HCCS, LDHA, LSM10, MAN2A2, METRN, NOM1, NQO2, PDCD5, PHF10, PSME1, RHBDD3, RNF4, SLC30A9, SNRPG, TMUB1, TPI1, TTC32, TXLNA, VIM, WBP11, ZFYVE19
TCC II — negativas intermediárias (treino) 35 genes	AARS2, ADAMTS3, AFF3, AKAP11, BIRC3, BMS1, C1GALT1, CCRL2, CDCA7, CDHR3, CFDP1, CPT1C, EPS15, EXOC3L4, FRMPD2, GRB10, IGHG1, ITPKA, LBH, MYO16, PATJ, PDE1A, PRKD2, RTRAF, SCLT1, SI, SLC24A2, SLC4A3, SPSB1, ST8SIA4, TBL1XR1, TGFBR1, TIMMDC1, TMEM163, TRIB2
TCC II — negativas difíceis (treino) 42 genes	ACKR4, BMP8B, CCL1, CCL19, CCL25, CCR9, CLCF1, CMTM1, CMTM7, CMTM8, CSF1, CXCL12, CXCR5, FLT3LG, GDF2, GFRA4, IFNL1, IL11, IL13RA1, IL25, KCNH1, KCNH2, KDM2A, KLK9, MPL, NFKB2, NFKBIB, OTUD7B, PIAS2, PIAS3, PRDX4, PRSS46P, PTK6, RNF138, RPS6KA5, SRMS, TET3, TNFSF13B, TNFSF14, TNFSF9, UBE2D2, ZAP70

Validação externa (as mesmas nos dois): INS, PTPN22, IL12B, CARD14, RUNX3.