UNIVERSIDADE POSITIVO

BACHARELADO EM ENGENHARIA DE SOFTWARE

Igor Felipe Viana
Bruno Rafael Hunoff de Freitas
Nicolas Czekoski Yasumoto
Laura Reded de Melo

Machine learning para classificação de proteínas associadas à psoríase a partir de k-mers de sequências de aminoácidos

CURITIBA
2026

Igor Felipe Viana
Bruno Rafael Hunoff de Freitas
Nicolas Czekoski Yasumoto
Laura Reded de Melo

MACHINE LEARNING PARA CLASSIFICAÇÃO DE PROTEÍNAS ASSOCIADAS À PSORÍASE A PARTIR DE K-MERS DE SEQUÊNCIAS DE AMINOÁCIDOS

Trabalho apresentado como requisito parcial na disciplina de Trabalho de Conclusão de Curso **I** da Universidade Positivo para obtenção do grau de **Bacharel em Engenharia de Software**

Orientador: Prof. Aryel Marlus Repula de Oliveira

CURITIBA
2026

RESUMO

A psoríase é uma doença inflamatória crônica imunomediada cujo diagnóstico, predominantemente clínico, ainda enfrenta limitações de acurácia e de acesso, sobretudo na atenção primária. Embora estudos de associação genômica ampla tenham consolidado marcadores genéticos da doença — como HLA-C*06:02, IL12B, IL23R, TRAF3IP2, TNFAIP3 e TNIP1 —, nenhum trabalho havia explorado a sequência de aminoácidos das proteínas codificadas por esses marcadores como base para classificação por machine learning. Este trabalho desenvolve e avalia uma pipeline computacional que classifica proteínas como associadas ou não associadas à psoríase a partir de sua sequência de aminoácidos, sem recorrer a alinhamento. Cada sequência é representada pela composição de k-mers (k=3, gerando 8.000 dimensões), reduzida por projeção aleatória gaussiana e consolidada em um vetor de dimensão fixa por mean pooling. O conjunto de dados, obtido do UniProt/Swiss-Prot, reúne 223 sequências — 111 positivas, derivadas dos genes notáveis dos loci de suscetibilidade confirmados por Tsoi et al. (2012) e de seus homólogos, e 112 negativas, organizadas em três níveis de dificuldade discriminativa: proteínas housekeeping, proteínas imunes não associadas à psoríase, e proteínas de doenças com sobreposição genética. Seis modelos supervisionados — Logistic Regression, SVM, Random Forest, Gradient Boosting, k-NN e Naive Bayes — foram comparados por validação cruzada estratificada de dez folds com otimização de hiperparâmetros via GridSearchCV, e por validação externa com proteínas não vistas no treinamento. Os três modelos principais — Regressão Logística, SVM e Random Forest — apresentaram desempenho consistentemente elevado, com ROC-AUC acima de 97% e MCC acima de 83% em todas as configurações testadas, sendo N=1.000 componentes a configuração de melhor desempenho geral. A validação externa revelou capacidade de generalização para proteínas imunes sistêmicas não treinadas da mesma família funcional dos marcadores de treinamento, com menor generalização para marcadores de vias distintas como a sinalização epitelial. Conclui-se pela viabilidade metodológica da representação por k-mers combinada com machine learning para classificação proteica de marcadores de psoríase, com a expansão do conjunto de dados para proteínas de vias funcionalmente distintas identificada como principal direção para trabalhos futuros.

Palavras-chave: Psoríase; classificação de proteínas; k-mers; projeção aleatória; machine learning.

ABSTRACT

Psoriasis is a chronic immune-mediated inflammatory disease whose diagnosis, predominantly clinical, still faces limitations in accuracy and access, particularly in primary care settings. Although genome-wide association studies have established genetic markers of the disease — including HLA-C*06:02, IL12B, IL23R, TRAF3IP2, TNFAIP3, and TNIP1 — no previous work had explored the amino acid sequences of the proteins encoded by these markers as a basis for machine learning classification. This work develops and evaluates a computational pipeline that classifies proteins as associated or non-associated with psoriasis based on their amino acid sequences, without resorting to sequence alignment. Each sequence is represented by its k-mer composition (k=3, generating 8,000 dimensions), reduced by Gaussian random projection, and consolidated into a fixed-length vector by mean pooling. The dataset, obtained from UniProt/Swiss-Prot, comprises 223 sequences — 111 positive, derived from the notable genes of the susceptibility loci confirmed by Tsoi et al. (2012) and their homologs, and 112 negative, organized into three levels of discriminative difficulty: housekeeping proteins, immune proteins not associated with psoriasis, and proteins from diseases with genetic overlap with psoriasis. Six supervised models — Logistic Regression, SVM, Random Forest, Gradient Boosting, k-NN, and Naive Bayes — were compared using stratified ten-fold cross-validation with hyperparameter optimization via GridSearchCV, and external validation with proteins unseen during training. The three main models — Logistic Regression, SVM, and Random Forest — achieved consistently high performance, with ROC-AUC above 97% and MCC above 83% across all tested configurations, with N=1,000 components yielding the best overall results. External validation demonstrated generalization capacity for unseen systemic immune proteins from the same functional family as the training markers, with lower generalization for markers from distinct pathways such as epithelial signaling. The results support the methodological feasibility of k-mer representation combined with machine learning for protein classification of psoriasis markers, with dataset expansion toward functionally distinct protein families identified as the primary direction for future work.

Keywords: Psoriasis; protein classification; k-mers; random projection; machine learning.

LISTA DE QUADROS

Quadro 1 — Desempenho dos classificadores com N=300.....32
Quadro 2 — Desempenho dos classificadores com N=400.....33
Quadro 3 — Desempenho dos classificadores com N=500.....33
Quadro 4 — Desempenho dos classificadores com N=1.000.....34
Quadro 5 — Resultados da validação externa.....35

SUMÁRIO

1 INTRODUÇÃO 10
1.1 JUSTIFICATIVA 11
1.2 OBJETIVOS 12
1.2.1 Objetivo Geral 12
1.2.2 Objetivos Específicos 12
2 REVISÃO BIBLIOGRÁFICA 14
2.1 TRABALHOS RELACIONADOS 14
2.1.1 Yang et al. (2021) — Classificação de psoríase por CNN versus dermatologistas 14
2.1.2 Huang et al. (2023) — Automatização do PASI por deep learning 15
2.1.3 Yin et al. (2015) — Polygenic Risk Score com SNPs e HLA 15
2.1.4 Ganatra et al. (2025) — Machine learning com SNPs, proteínas e dados clínicos 15
2.1.5 Cipriano et al. (2025) — Random Forest para doenças dermatológicas no contexto brasileiro 16
2.1.6 Guo et al. (2021) — Classificação de proteínas por k-mers e Naive Bayes 16
2.2 ANÁLISE CRÍTICA GERAL 17
2.3 TIPO E OBJETO DE PESQUISA 17
2.4 POPULAÇÃO OU AMOSTRA DE ESTUDO 18
2.4.1 Critérios de Inclusão 19
2.4.1.1 Grupo positivo — proteínas de psoríase: 19
2.4.1.2 Grupo negativo — proteínas controle: 19
2.4.2 Critérios de Exclusão 20
2.4.2.1 Grupo positivo: 20
2.4.2.2 Grupo negativo: 20
3 DESCRIÇÃO DO PROCESSO DE COLETA DE DADOS 22
3.1 COLETA DAS PROTEÍNAS POSITIVAS 22
3.2 COLETA DAS PROTEÍNAS NEGATIVAS 22
3.3 METODOLOGIA PARA REVISÃO 23
3.3.1 Verificação de resíduos desconhecidos 23
4 DESCRIÇÃO DO PROCESSO DE ANÁLISE DE DADOS 25
4.1 ANÁLISE MATEMÁTICA E ESTATÍSTICA 25
4.1.1 Representação por K-mers 25
4.1.2 Projeção Aleatória Gaussiana 26
4.1.3 Modelos de Classificação Supervisionada 27
4.1.4 Métricas de Avaliação 28
4.1.5 VALIDAÇÃO CRUZADA 29
4.1.6 Validação Externa 30
4.2 ALGORITMOS E FRAMEWORKS 30
4.2.1 Coleta e manipulação de dados: 30
4.2.2 Modelos de classificação e avaliação: 30
4.2.3 Bancos de dados utilizados para coleta: 31

4.2.4 Ambiente de desenvolvimento: 31
5 RESULTADOS PRELIMINARES 32
5.1 EXPERIMENTO - GRUPO CONTROLE 32
5.2 EXPERIMENTO - VALIDAÇÃO EXTERNA 34
5.3 SÍNTESE DOS RESULTADOS 35
6 DISCUSSÃO E CONCLUSÃO 37
6.1 Trabalhos Futuros 38
REFERÊNCIAS 40

1 INTRODUÇÃO

A psoríase é uma doença inflamatória crônica de caráter imunomediado que afeta entre 0,51% e 11,43% da população adulta mundial, manifestando-se predominantemente na pele, unhas e articulações (McMullen et al., 2025). Sua patogênese envolve uma resposta imune desregulada caracterizada pela ativação exacerbada das vias Th1 e Th17, com dependência do fator de necrose tumoral alfa (TNF-α) em indivíduos geneticamente suscetíveis (Tsoi et al., 2012). O diagnóstico é predominantemente clínico, baseado na observação de placas eritematosas escamosas, sendo a biópsia cutânea com análise histopatológica considerada o padrão-ouro nos casos de apresentação atípica — um procedimento invasivo, demorado e dependente de profissional especializado (McMullen et al., 2025).

Estudos de associação genômica ampla (GWAS) identificaram mais de 100 loci de suscetibilidade à psoríase, com uma meta-análise recente envolvendo 36.466 casos e 458.078 controles reportando 109 loci distintos, incluindo 46 não previamente descritos (Dand et al., 2025). Entre os marcadores mais consolidados, destacam-se HLA-C*06:02, IL12B, IL23R, TRAF3IP2, TNFAIP3 e TNIP1, confirmados por meta-análise de cinco estudos GWAS envolvendo 10.588 casos e 22.806 controles de ancestralidade europeia (Tsoi et al., 2012; Harden et al., 2015). A aplicação de machine learning para predição de psoríase a partir de dados genéticos tem sido investigada principalmente por meio de modelos baseados em variantes pontuais de DNA (SNPs) e alelos HLA, que classificam o risco individual de um paciente a partir de seu perfil genético, com melhor AUC reportada de 0,8583 (Yin et al., 2015). No entanto, uma revisão sistemática recente identificou que 29 dos 30 estudos de machine learning aplicados à psoríase utilizam análise de imagens como entrada, e nenhum explorou as sequências de aminoácidos das proteínas codificadas pelos marcadores genéticos como base preditiva — representando uma lacuna metodológica ainda não investigada na literatura (McMullen et al., 2025).

Diante dessa lacuna, o presente trabalho propõe uma abordagem in silico para predição de suscetibilidade à psoríase baseada na análise de sequências de aminoácidos das proteínas codificadas pelos marcadores genéticos confirmados da doença. A metodologia emprega a representação de sequências proteicas por k-mers — fragmentos de tamanho fixo de aminoácidos — convertidos em vetores

numéricos de dimensão fixa por meio de projeção aleatória gaussiana, viabilizando a comparação de proteínas de diferentes tamanhos. Modelos supervisionados de classificação são treinados e avaliados sobre esse conjunto de dados para distinguir proteínas associadas à psoríase de proteínas não associadas, incluindo controles de diferentes graus de dificuldade discriminativa.

1.1 JUSTIFICATIVA

A psoríase representa um problema de saúde pública de relevância global, com impacto significativo na qualidade de vida dos pacientes e demanda crescente por ferramentas diagnósticas acessíveis e não invasivas. O diagnóstico clínico, embora seja o método primário, apresenta taxa de acerto de apenas 45% entre médicos generalistas sem apoio de dados histopatológicos (Cipriano et al., 2025), evidenciando a necessidade de ferramentas auxiliares que possam ser aplicadas em contextos de atenção primária, como o Sistema Único de Saúde (SUS), onde o acesso a dermatologistas especializados é limitado.

A literatura científica demonstra que abordagens baseadas em machine learning têm potencial para superar limitações do diagnóstico tradicional. Modelos de análise de imagens já alcançaram desempenho equivalente ao de 230 dermatologistas (Yang et al., 2021), enquanto modelos baseados em SNPs genéticos demonstraram AUC de até 0,8583 (Yin et al., 2015). Contudo, conforme identificado por McMullen et al. (2025), a quase totalidade dos estudos existentes depende de imagens clínicas ou dados histopatológicos, e nenhum explorou a análise de sequências proteicas como base preditiva — representando uma direção metodológica inédita com potencial de contribuição científica relevante.

A abordagem proposta neste trabalho oferece vantagens metodológicas distintas: não requer coleta de imagens, avaliação clínica presencial ou exames invasivos, podendo ser aplicada a partir de dados proteômicos obtidos de bancos públicos. Adicionalmente, por operar sobre sequências proteicas dos próprios marcadores genéticos confirmados da doença, a abordagem é biologicamente fundamentada e interpretável, alinhando-se à tendência de medicina de precisão baseada em biomarcadores moleculares (Ran et al., 2019).

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Desenvolver e avaliar uma pipeline in silico de classificação de proteínas associadas à psoríase baseada em representação por k-mers de sequências de aminoácidos e modelos supervisionados de machine learning, visando identificar candidatos a biomarcadores proteicos da doença.

1.2.2 Objetivos Específicos

- Realizar revisão sistemática da literatura sobre marcadores genéticos confirmados de psoríase e métodos existentes de diagnóstico e predição da doença com auxílio de inteligência artificial;
- Selecionar e coletar as sequências proteicas dos genes notáveis dos 21 loci de suscetibilidade conhecidos confirmados por Tsoi et al. (2012), incluindo homólogos de múltiplos organismos obtidos do banco UniProt/Swiss-Prot;
- Construir um conjunto de dados balanceado com proteínas positivas — associadas à psoríase — e proteínas negativas de diferentes graus de dificuldade discriminativa, incluindo proteínas housekeeping, proteínas imunes não associadas à psoríase, e proteínas de doenças com sobreposição genética com a psoríase — doença de Crohn e artrite reumatoide, selecionadas com base em Tsoi et al. (2012) e na literatura específica de cada doença (Tsianos et al., 2012; Li; Begovich, 2009);
- Implementar pipeline de representação de sequências proteicas por k-mers com k=3, gerando vetores numéricos de dimensão fixa por meio de projeção aleatória gaussiana, conforme abordagem estabelecida por Guo et al. (2021);
- Treinar e comparar modelos supervisionados de classificação — Logistic Regression, Random Forest, SVM, Gradient Boosting, k-NN e Naive Bayes — utilizando validação cruzada estratificada de 10 folds, com base nos modelos avaliados na literatura de classificação proteica e predição de psoríase (Guo et al., 2021; Chandran et al., 2025; Cipriano et al., 2025);
- Avaliar a capacidade de generalização dos modelos por meio de validação externa com proteínas não incluídas no treinamento, incluindo marcadores confirmados de psoríase de vias funcionalmente distintas das representadas no

conjunto de treinamento, identificando o escopo e os limites de generalização da abordagem proposta.

2 REVISÃO BIBLIOGRÁFICA

Este capítulo apresenta a fundamentação teórica necessária para a compreensão do trabalho, abordando quatro eixos temáticos principais: a caracterização clínica e epidemiológica da psoríase, as bases genéticas da doença estabelecidas por estudos de associação genômica ampla, a representação de sequências proteicas por k-mers como abordagem de bioinformática computacional, e o estado da arte do aprendizado de máquina aplicado à dermatologia e à predição genética de doenças.

2.1 TRABALHOS RELACIONADOS

Esta seção apresenta os principais trabalhos que abordam o tema em estudo sob perspectivas complementares: diagnóstico de psoríase por imagem com auxílio de inteligência artificial, predição genética da doença por modelos de machine learning, e classificação de proteínas por representação de sequências com k-mers.

2.1.1 Yang et al. (2021) — Classificação de psoríase por CNN versus dermatologistas

Yang et al. (2021) desenvolveram e avaliaram uma rede neural convolucional treinada com imagens dermatoscópicas para classificação de psoríase em comparação ao desempenho de 230 dermatologistas. O modelo alcançou sensibilidade de 0,929 e especificidade de 0,952, resultado estatisticamente equivalente à média dos especialistas humanos.

Ponto forte: demonstra que modelos de visão computacional podem atingir desempenho de nível especialista em dermatologia, com validação robusta em grande número de avaliadores humanos.

Ponto fraco: depende integralmente de imagens de alta qualidade e avaliação presencial ou fotográfica do paciente, sendo inaplicável em contextos sem acesso a dermatoscópio ou câmera adequada.

2.1.2 Huang et al. (2023) — Automatização do PASI por deep learning

Huang et al. (2023) propuseram um sistema de avaliação automatizada de severidade de psoríase baseado em deep learning para pontuação do índice PASI, treinado com 14.096 imagens de 2.367 pacientes e comparado ao desempenho de 43 dermatologistas. O modelo apresentou erro médio absoluto de 3,12 contra 4,67 dos especialistas.

Ponto forte: aborda a subjetividade inerente à avaliação manual do PASI, demonstrando que a automação pode reduzir variabilidade inter-avaliador.

Ponto fraco: restrito à avaliação de severidade em pacientes já diagnosticados, não contribuindo para o diagnóstico inicial da doença.

2.1.3 Yin et al. (2015) — Polygenic Risk Score com SNPs e HLA

Yin et al. (2015) desenvolveram um modelo preditivo de psoríase baseado em Polygenic Risk Score ponderado, combinando 14 variantes genéticas incluindo o alelo HLA-C*06:02, avaliado em 8.819 amostras de população Han Chinesa. O modelo SNP-HLA alcançou AUC de 0,8583, com sensibilidade de 84,7% e especificidade de 81,7%.

Ponto forte: é o estudo com maior AUC reportada para predição genética de psoríase, demonstrando que a combinação de múltiplos marcadores supera significativamente qualquer marcador isolado.

Ponto fraco: baseado em variantes de SNPs genotipadas individualmente em cada paciente, exigindo dados genéticos pessoais — o que limita a aplicabilidade em contextos sem infraestrutura de genotipagem. Validado exclusivamente em população Han Chinesa, sem replicação em outras etnias.

2.1.4 Ganatra et al. (2025) — Machine learning com SNPs, proteínas e dados clínicos

Ganatra et al. (2025) propuseram modelos de machine learning para distinguir artrite psoriásica de psoríase sem artrite, combinando marcadores genéticos (SNPs), proteínas séricas e características clínicas. O melhor modelo — Random Forest —

alcançou AUC de 0,733, com SNPs de TNFAIP3, IL23R e TNIP1 entre os marcadores de maior contribuição.

Ponto forte: demonstra que a combinação multimodal de dados genéticos, proteicos e clínicos melhora o desempenho preditivo, e utiliza marcadores diretamente relacionados aos adotados no presente trabalho.

Ponto fraco: abordagem multimodal exige coleta simultânea de múltiplos tipos de dados do paciente, aumentando a complexidade de implementação clínica.

2.1.5 Cipriano et al. (2025) — Random Forest para doenças dermatológicas no contexto brasileiro

Cipriano et al. (2025) desenvolveram modelo de Random Forest para classificação de seis doenças dermatológicas eritemato-descamativas — incluindo psoríase — baseado exclusivamente em dados clínicos, sem suporte histopatológico, treinado com dataset público do repositório UCI. O modelo atingiu ROC-AUC de 0,98 para psoríase e acurácia geral de 86%.

Ponto forte: contextualiza o problema no cenário brasileiro, demonstrando viabilidade de modelos de ML para apoio ao diagnóstico dermatológico na atenção primária do SUS. É o único estudo em português na literatura da área.

Ponto fraco: utiliza dados clínicos coletados por médicos em consulta presencial, não sendo aplicável sem avaliação especializada. O dataset de treinamento não é de origem brasileira, limitando a generalização para a população local.

2.1.6 Guo et al. (2021) — Classificação de proteínas por k-mers e Naive Bayes

Guo et al. (2021) propuseram modelo de identificação de proteínas ligantes de hormônios baseado em representação por k-mers de sequências de aminoácidos, com k=3, gerando vetores de 8.000 dimensões. O modelo Naive Bayes alcançou acurácia de 95,45%, sensibilidade de 94,17% e especificidade de 96,73% em validação cruzada de 10 folds, superando Random Forest, Logistic Regression e LDA na mesma tarefa.

Ponto forte: estabelece a metodologia de representação proteica por k-mers com k=3 como abordagem eficaz para classificação binária de proteínas, fornecendo a base metodológica diretamente adotada no presente trabalho.

Ponto fraco: aplicado a um problema de classificação de proteínas com negativos selecionados aleatoriamente do UniProt, sem critérios funcionais explícitos de exclusão — limitação reconhecida pelos próprios autores. Não aborda doenças humanas como objeto de classificação.

2.2 ANÁLISE CRÍTICA GERAL

Os trabalhos analisados podem ser agrupados em duas grandes categorias: abordagens baseadas em imagem, que demonstram alto desempenho mas dependem de avaliação presencial e infraestrutura fotográfica; e abordagens baseadas em dados genéticos ou moleculares, que operam sobre dados obtidos a partir de amostras biológicas, com maior potencial de automação e escalabilidade. Nenhum dos trabalhos revisados combina representação de sequências proteicas completas dos marcadores genéticos da psoríase com modelos supervisionados de classificação — lacuna explicitamente identificada por McMullen et al. (2025) e que fundamenta a contribuição original do presente trabalho. Adicionalmente, os estudos de predição genética existentes classificam **indivíduos** com base em seus perfis de SNPs, enquanto a abordagem proposta classifica **proteínas** com base em seus padrões de sequência — uma distinção metodológica fundamental que amplia o escopo de aplicação para análise proteômica in silico.

2.3 TIPO E OBJETO DE PESQUISA

O presente trabalho caracteriza-se como uma pesquisa de natureza quantitativa, uma vez que os resultados são expressos por métricas numéricas objetivas — acurácia, F1-score, precisão, sensibilidade, especificidade, ROC-AUC e MCC — e as análises são conduzidas por meio de processamento computacional de dados biológicos estruturados. Do ponto de vista de sua classificação metodológica, trata-se de uma pesquisa bibliográfica combinada com estudo experimental in silico: bibliográfica por fundamentar-se em revisão da literatura científica para seleção dos marcadores genéticos e definição da metodologia; e experimental por desenvolver,

implementar e avaliar uma pipeline computacional original sobre dados coletados de bancos públicos.

O objeto de pesquisa é a classificação computacional de proteínas como associadas ou não à psoríase, a partir da representação de suas sequências de aminoácidos por k-mers, utilizando modelos supervisionados de aprendizado de máquina. O foco central do estudo é a avaliação da viabilidade e do desempenho dessa abordagem in silico como ferramenta auxiliar de identificação de biomarcadores proteicos da doença, contribuindo para o campo da medicina de precisão baseada em dados moleculares.

2.4 POPULAÇÃO OU AMOSTRA DE ESTUDO

A pesquisa não envolve participantes humanos diretamente. A população de estudo é definida como o conjunto de proteínas humanas — e seus homólogos em outros organismos — disponíveis no banco de dados UniProt/Swiss-Prot com anotação manual revisada. Dado que o exame de toda essa população seria computacionalmente inviável e desnecessário para os objetivos do trabalho, foi definida uma amostra composta por dois grupos distintos.

O grupo positivo — proteínas candidatas a biomarcadores de psoríase — compreende 111 sequências proteicas distribuídas entre os produtos proteicos dos 28 genes notáveis dos 21 loci de suscetibilidade conhecidos confirmados por Tsoi et al. (2012), incluindo homólogos de múltiplos organismos para enriquecer a representação de cada marcador. O grupo negativo — proteínas controle — compreende sequências proteicas de três subgrupos funcionalmente distintos: proteínas housekeeping, proteínas imunes não associadas à psoríase, e proteínas de doenças com sobreposição genética com a psoríase — com volume variando entre os experimentos conduzidos, conforme detalhado adiante.

O grupo negativo totalizou 112 sequências, compostas pelos três subgrupos funcionalmente distintos descritos acima. A proporção final entre grupos positivo e negativo — 111 sequências positivas para 112 negativas — é de aproximadamente 1:1, considerada adequada para o treinamento de modelos supervisionados de classificação binária sem necessidade de técnicas adicionais de balanceamento.

A delimitação do conjunto de marcadores positivos aos genes notáveis dos 21 loci confirmados por Tsoi et al. (2012) foi uma escolha metodológica intencional. Estudos posteriores expandiram progressivamente o número de loci associados à psoríase — para 63 loci em Tsoi et al. (2017) e para 109 loci em Dand et al. (2025) — sem invalidar os marcadores identificados em 2012, que permanecem os mais replicados e com maiores tamanhos de efeito documentados na literatura. O objetivo central deste trabalho é desenvolver e validar uma abordagem in silico de classificação proteica baseada em machine learning, para o qual o conjunto de 28 marcadores consolidados de 2012 é suficiente e adequado. A expansão para os loci identificados em estudos posteriores constitui uma direção natural para trabalhos futuros.

2.4.1 Critérios de Inclusão

2.4.1.1 Grupo positivo — proteínas de psoríase:

- Proteínas codificadas pelos genes listados como "notable genes" na Tabela 1 de Tsoi et al. (2012), correspondendo aos 21 loci de suscetibilidade conhecidos à psoríase em populações de ancestralidade europeia;
- Entradas com status "Reviewed" no UniProt/Swiss-Prot, indicando anotação manual por curadores especializados;
- Homólogos de múltiplos organismos do mesmo gene, desde que também classificados como "Reviewed" no UniProt/Swiss-Prot;
- Máximo de 10 sequências por gene, para evitar dominância de proteínas com maior número de homólogos disponíveis;
- Sequências compostas exclusivamente pelos 20 aminoácidos canônicos, sem resíduos desconhecidos.

2.4.1.2 Grupo negativo — proteínas controle:

- Proteínas housekeeping com funções em metabolismo energético, estrutura celular ou transporte, sem anotação em processos imunes ou inflamatórios segundo o Gene Ontology;
- Proteínas imunes com função confirmada, porém sem associação genética com psoríase em estudos GWAS — selecionadas como negativos de maior dificuldade discriminativa;

- Proteínas codificadas por marcadores genéticos confirmados de doença de Crohn (Tsianos et al., 2012) e artrite reumatoide (Li; Begovich, 2009) com sobreposição de vias biológicas com a psoríase, porém sem associação direta com a doença;
- Entradas com status "Reviewed" no UniProt/Swiss-Prot;
- Máximo de 4 sequências por proteína, para manutenção do balanceamento com o grupo positivo;
- Sequências compostas exclusivamente pelos 20 aminoácidos canônicos, sem resíduos desconhecidos.

2.4.2 Critérios de Exclusão

2.4.2.1 Grupo positivo:

- Gene FLJ16341, listado no mesmo locus que REL no Tsoi et al. (2012), por não possuir entrada proteica caracterizada funcionalmente disponível no UniProt à época da condução deste trabalho;
- Sequências com resíduos desconhecidos representados pelos caracteres X, Z ou B, que comprometem a integridade da representação por k-mers;
- Entradas não revisadas (TrEMBL) do UniProt, por apresentarem anotação automática sem verificação experimental;
- Sequências adicionais de um mesmo gene que ultrapassem o limite de 10 homólogos por proteína.

2.4.2.2 Grupo negativo:

- Proteínas com qualquer anotação no Gene Ontology em termos relacionados a resposta imune à psoríase, inflamação cutânea ou vias Th17 — para evitar contaminação do grupo controle com proteínas funcionalmente próximas aos positivos;
- Proteínas de doenças com sobreposição genética direta com psoríase nos mesmos loci utilizados como positivos — como STAT4, compartilhado entre artrite reumatoide e psoríase segundo Tsoi et al. (2012);
- Sequências com resíduos desconhecidos representados pelos caracteres X, Z ou B;
- Entradas não revisadas (TrEMBL) do UniProt;

- Sequências adicionais de um mesmo gene que ultrapassem o limite de 4 homólogos por proteína.

3 DESCRIÇÃO DO PROCESSO DE COLETA DE DADOS

O objetivo da coleta de dados deste trabalho é reunir as sequências de aminoácidos das proteínas necessárias para o treinamento e avaliação dos modelos de classificação. Por tratar-se de uma pesquisa in silico, a coleta não envolve participantes humanos nem experimentos laboratoriais — os dados são obtidos integralmente de bancos de dados biológicos públicos e de acesso aberto.

A coleta é dividida em duas etapas correspondentes aos dois grupos do dataset: proteínas positivas e proteínas negativas.

3.1 COLETA DAS PROTEÍNAS POSITIVAS

As sequências proteicas do grupo positivo foram obtidas do banco UniProt/Swiss-Prot — seção de entradas revisadas manualmente — por meio de buscas individuais para cada um dos 28 genes notáveis identificados na Tabela 1 de Tsoi et al. (2012). Para cada gene, a busca foi realizada utilizando o nome oficial do gene como termo de pesquisa, com filtro de status "Reviewed" aplicado para garantir que apenas entradas com anotação manual e verificação experimental fossem incluídas. Foram coletadas todas as entradas disponíveis para cada gene sem restrição de organismo, incluindo homólogos de múltiplos organismos — como Homo sapiens, Mus musculus, Rattus norvegicus, Bos taurus e Sus scrofa — seguindo a recomendação de Guo et al. (2021) de enriquecer o dataset com homólogos para capturar padrões de k-mers conservados evolutivamente. As sequências foram baixadas no formato FASTA, padrão universal em bioinformática para representação de sequências biológicas.

3.2 COLETA DAS PROTEÍNAS NEGATIVAS

As sequências do grupo negativo foram obtidas pelo mesmo procedimento — busca no UniProt/Swiss-Prot com filtro "Reviewed" e download em formato FASTA — para três subgrupos de proteínas:

O subgrupo housekeeping foi composto por proteínas humanas com funções em metabolismo energético, estrutura celular e transporte, selecionadas com base em seu papel biológico bem estabelecido e distância funcional das vias imunológicas

associadas à psoríase. O subgrupo de proteínas imunes não associadas à psoríase foi composto por proteínas com função imunológica confirmada, porém sem associação genética com psoríase em estudos GWAS, selecionadas como negativos de maior dificuldade discriminativa — estratégia denominada hard negatives na literatura de classificação proteica (Guo et al., 2021). O subgrupo de doenças com sobreposição genética foi composto por proteínas codificadas por marcadores genéticos confirmados de doença de Crohn (NOD2, ATG16L1, IRGM) e artrite reumatoide (PTPN22, CTLA4, PADI4, TRAF1), doenças que compartilham loci de suscetibilidade com a psoríase segundo Tsoi et al. (2012), selecionadas a partir de seus respectivos estudos de referência (Tsianos et al., 2012; Li; Begovich, 2009).

Todas as sequências coletadas foram armazenadas em arquivos FASTA individuais por proteína, organizados em dois diretórios distintos — positivos e negativos — para posterior processamento pela pipeline de k-mers.

3.3 METODOLOGIA PARA REVISÃO

Após a coleta, todas as sequências foram submetidas a um processo de revisão e filtragem para garantir a qualidade e adequação dos dados antes do treinamento dos modelos. Este processo operacionaliza os critérios de exclusão definidos na seção 2.4.2 e é composto pelas seguintes etapas:

3.3.1 Verificação de resíduos desconhecidos

Cada sequência foi inspecionada para identificação dos caracteres X, Z e B — representações de aminoácidos desconhecidos ou ambíguos no formato FASTA. Sequências contendo qualquer um desses caracteres foram descartadas, pois comprometem a integridade da representação por k-mers ao introduzir fragmentos não pertencentes ao vocabulário dos 20 aminoácidos canônicos, conforme procedimento adotado por Guo et al. (2021).

3.3.2 Controle do número de sequências por proteína

Para evitar dominância de proteínas com maior número de homólogos disponíveis no UniProt — o que poderia introduzir viés no treinamento ao fazer com

que o modelo aprenda desproporcionalmente os padrões de k-mers de certas proteínas —, foi aplicado um limite máximo de 10 sequências por proteína no grupo positivo e 4 sequências por proteína no grupo negativo. Quando o número de homólogos disponíveis excedia o limite, foram priorizadas as sequências de organismos modelo padrão em biologia molecular: Homo sapiens, Mus musculus, Rattus norvegicus, Bos taurus e Sus scrofa.

3.3.3 Verificação de sobreposição entre grupos

Foi realizada verificação manual para garantir que nenhuma proteína presente no grupo negativo estivesse também representada no grupo positivo — especialmente relevante para proteínas de doenças com sobreposição genética com a psoríase, como STAT4, que aparece tanto como marcador de artrite reumatoide quanto como newly identified loci no Tsoi et al. (2012), tendo sido excluída do grupo negativo por essa razão.

3.3.4 Balanceamento do dataset

Após a aplicação de todos os filtros, o dataset resultante foi verificado quanto ao balanceamento entre os grupos positivo e negativo. O grupo positivo totalizou 111 sequências e o grupo negativo 112 sequências — proporção de aproximadamente 1:1 —, considerada adequada para o treinamento de modelos supervisionados de classificação binária sem necessidade de técnicas adicionais de balanceamento como oversampling ou undersampling (Guo et al., 2021).

3.3.5 Organização final dos dados

As sequências aprovadas em todas as etapas de revisão foram mantidas nos arquivos FASTA originais, organizadas nos diretórios de positivos e negativos, prontas para processamento pela pipeline de representação por k-mers descrita na seção seguinte. O label de cada sequência — 1 para positivo e 0 para negativo — foi derivado automaticamente do diretório de origem, sem necessidade de anotação manual adicional.

4 DESCRIÇÃO DO PROCESSO DE ANÁLISE DE DADOS

O processo de análise de dados deste trabalho compreende três etapas sequenciais: representação das sequências proteicas como vetores numéricos por meio de k-mers, treinamento e avaliação de modelos supervisionados de classificação, e validação externa com proteínas não incluídas no treinamento.

4.1 ANÁLISE MATEMÁTICA E ESTATÍSTICA

4.1.1 Representação por K-mers

Dada uma sequência proteica P composta por L aminoácidos:

$$P = R_1R_2R_3...R_L$$

onde R_i representa o i-ésimo resíduo de aminoácido, os k-mers são todos os fragmentos contíguos de tamanho k extraídos por uma janela deslizante ao longo da sequência. Para k=3, cada k-mer é um tripeptídeo R_i R_{i+1} R_{i+2}, e o número total de k-mers extraídos de uma sequência de comprimento L é L - k + 1.

Com 20 aminoácidos canônicos e k=3, o vocabulário total de k-mers possíveis é:

$$|V| = 20^3 = 8.000$$

A representação de cada sequência é um vetor de frequências $f \in \mathbb{R}^{8000}$, onde cada componente f_i corresponde à frequência relativa do i-ésimo k-mer do vocabulário na sequência:

$$f_i = \text{contagem}(\text{kmer}_i) / (L - k + 1)$$

Esta normalização pela quantidade total de k-mers garante que sequências de comprimentos diferentes produzam vetores comparáveis, sendo esta uma das propriedades fundamentais da abordagem — independência do comprimento da proteína original (Guo et al., 2021).

A escolha de k=3 é justificada pelo equilíbrio entre capacidade representacional e esparsidade: k=2 gera apenas 400 dimensões, com perda de

especificidade estrutural; k=4 gera 160.000 dimensões, levando à maldição da dimensionalidade em datasets de tamanho moderado (Guo et al., 2021).

4.1.2 Projeção Aleatória Gaussiana

O vetor de frequências de k-mers de dimensão 8.000 é submetido a uma etapa de redução de dimensionalidade por meio de Projeção Aleatória Gaussiana (Gaussian Random Projection), que projeta o vetor original em um espaço de menor dimensão N_COMPONENTS, preservando aproximadamente as distâncias entre os pontos segundo o Lema de Johnson-Lindenstrauss.

Na implementação adotada, a projeção opera sobre a matriz posicional de k-mers (L-k+1, 8.000) — onde cada linha representa uma janela da sequência — aplicando a transformação:

$$x' = (1/\sqrt{N_COMPONENTS}) \cdot R \cdot x_i$$

Onde $x_i \in \mathbb{R}^{8000}$ é o vetor de uma janela, $R \in \mathbb{R}^{Nx8000}$ é uma matriz de projeção com entradas amostradas de uma distribuição normal N(0,1), e $x' \in \mathbb{R}^N$ é o vetor projetado correspondente. O vetor final da proteína é obtido por mean pooling sobre as linhas projetadas — média aritmética das representações de todas as janelas — produzindo um único vetor de dimensão fixa N, independentemente do comprimento original da sequência.

Neste trabalho foram avaliados quatro valores de N_COMPONENTS — 300, 400, 500 e 1.000 — com o objetivo de identificar o impacto da dimensionalidade do vetor projetado no desempenho dos modelos de classificação. Os resultados comparativos são apresentados na seção de Resultados Preliminares.

4.1.3 Modelos de Classificação Supervisionada

Seis modelos supervisionados de classificação binária foram treinados e comparados. Para cada modelo, o label positivo (1) corresponde a proteínas associadas à psoríase e o label negativo (0) a proteínas controle.

Logistic Regression Modelo linear que estima a probabilidade de pertencimento à classe positiva por meio da função sigmoide aplicada a uma combinação linear das features:

$$P(y=1|x) = 1 / (1 + e^{(-\theta^T x)})$$

Onde θ é o vetor de pesos aprendido durante o treinamento por minimização da função de custo de entropia cruzada. É o modelo mais interpretável do conjunto avaliado.

Support Vector Machine (SVM com kernel RBF) Modelo que busca o hiperplano de margem máxima que separa as classes no espaço de features transformado pelo kernel de função de base radial (RBF):

$$K(x_i, x□) = \exp(-\gamma||x_i - x□||^2)$$

O kernel RBF permite capturar fronteiras de decisão não lineares, sendo adequado para dados de alta dimensionalidade como vetores de k-mers.

Random Forest Ensemble de árvores de decisão treinadas por bootstrap sampling, onde a predição final é determinada por votação majoritária entre as árvores individuais. Cada árvore é treinada em um subconjunto aleatório das features, reduzindo a correlação entre os estimadores e melhorando a generalização. A impureza de cada nó é medida pelo índice de Gini:

$$Gini(t) = 1 - \Sigma\, p(c|t)^2$$

Onde p(c|t) é a proporção de amostras da classe c no nó t.

Gradient Boosting Ensemble sequencial de árvores de decisão rasas, onde cada árvore é treinada para corrigir os erros residuais da árvore anterior, minimizando iterativamente uma função de perda diferenciável. É a base algorítmica do XGBoost, citado por Cipriano et al. (2025) como um dos melhores modelos para classificação de doenças dermatológicas.

k-Nearest Neighbors (kNN, k=5) Algoritmo não paramétrico que classifica uma amostra com base na classe majoritária de seus k vizinhos mais próximos no espaço de features, medida pela distância euclidiana. Incluído por ser um baseline clássico

de comparação, apesar de sua limitação conhecida em espaços de alta dimensionalidade.

Naive Bayes Classificador probabilístico baseado no Teorema de Bayes com suposição de independência condicional entre as features:

$P(y|x) = P(y) \cdot \Pi\, P(x_i|y) / P(x)$

Incluído por ser o melhor modelo reportado por Guo et al. (2021) para classificação proteica por k-mers, permitindo comparação direta com o artigo metodológico de referência.

4.1.4 Métricas de Avaliação

O desempenho dos modelos foi avaliado por um conjunto de métricas complementares, calculadas sobre os resultados da validação cruzada estratificada de 10 folds:

Acurácia: proporção de classificações corretas sobre o total de amostras.

$AC = (TP + TN) / (TP + TN + FP + FN)$

Precisão: proporção de verdadeiros positivos entre todas as amostras classificadas como positivas — relevante para minimizar falsos alarmes.

$P = TP / (TP + FP)$

Sensibilidade (Recall): proporção de verdadeiros positivos entre todas as amostras efetivamente positivas — relevante para minimizar casos não identificados.

$S = TP / (TP + FN)$

Especificidade: proporção de verdadeiros negativos entre todas as amostras efetivamente negativas.

$E = TN / (TN + FP)$

F1-Score: média harmônica entre precisão e sensibilidade, métrica de equilíbrio entre os dois critérios.

$$F1 = 2 \cdot (P \cdot S) / (P + S)$$

ROC-AUC: área sob a curva ROC (Receiver Operating Characteristic), que mede a capacidade discriminativa do modelo entre as classes positiva e negativa independentemente do limiar de decisão. Valores próximos de 1,0 indicam discriminação perfeita; valor de 0,5 equivale a classificação aleatória.

MCC (Matthews Correlation Coefficient): métrica robusta para avaliação de classificadores binários, especialmente em datasets com proporções variadas entre classes, calculada como:

$$MCC = (TP \cdot TN - FP \cdot FN) / \sqrt{((TP+FP)(TP+FN)(TN+FP)(TN+FN))}$$

Valores de MCC variam entre -1 e +1, onde +1 indica predição perfeita, 0 equivale a predição aleatória e -1 indica predição inversa completa. O MCC é considerado a métrica mais informativa para classificação binária por sintetizar em um único valor o desempenho em todas as categorias da matriz de confusão (Guo et al., 2021).

4.1.5 VALIDAÇÃO CRUZADA

A avaliação dos modelos foi conduzida por validação cruzada estratificada de 10 folds (StratifiedKFold), que divide o dataset em 10 subconjuntos preservando a proporção entre classes em cada fold. Em cada iteração, 9 folds são utilizados para treinamento e 1 fold para teste, repetindo o processo 10 vezes de forma que cada amostra seja utilizada exatamente uma vez como dado de teste. Os hiperparâmetros de cada modelo foram otimizados automaticamente via GridSearchCV dentro de cada fold, garantindo que a busca de hiperparâmetros não vaze informação entre treino e teste. A métrica final reportada é a média e o desvio padrão das 10 iterações (Guo et al., 2021).

4.1.6 Validação Externa

Complementarmente à validação cruzada, foi conduzida uma validação externa com proteínas não incluídas no conjunto de treinamento, avaliando a

capacidade de generalização dos modelos para dados completamente novos. Foram testadas cinco proteínas representando quatro categorias distintas: proteína negativa treinada (INS), proteína negativa não treinada (PTPN22), proteína positiva treinada (IL12B) e proteínas positivas não treinadas de vias funcionalmente distintas (CARD14 — marcador epitelial; RUNX3 — marcador imune sistêmico). Esta validação permite distinguir modelos que memorizam padrões do treinamento daqueles que aprendem características estruturais generalizáveis das proteínas.

4.2 ALGORITMOS E FRAMEWORKS

A implementação da pipeline foi realizada integralmente em linguagem Python 3, com os seguintes frameworks e bibliotecas:

4.2.1 Coleta e manipulação de dados:

- **BioPython** — leitura e parsing de arquivos no formato FASTA
- **Pandas** — organização e manipulação do dataset em estrutura tabular
- **NumPy** — operações matriciais e vetoriais
- **Representação por k-mers e projeção:**
- **NumPy** — cálculo de frequências de k-mers e aplicação de mean pooling
- **scikit-learn** — implementação de Gaussian Random Projection para redução de dimensionalidade de 8.000 para N componentes, com N avaliado nos valores 300, 400, 500 e 1.000

4.2.2 Modelos de classificação e avaliação:

- **scikit-learn** — implementação dos seis modelos supervisionados avaliados (LogisticRegression, SVC, RandomForestClassifier, GradientBoostingClassifier, KNeighborsClassifier, GaussianNB), otimização de hiperparâmetros via GridSearchCV, validação cruzada estratificada por StratifiedKFold, e cálculo de todas as métricas de avaliação

4.2.3 Bancos de dados utilizados para coleta:

- **UniProt/Swiss-Prot** (https://www.uniprot.org) — sequências FASTA de todas as proteínas positivas e negativas, com filtro de entradas revisadas
- **NCBI Gene** (https://www.ncbi.nlm.nih.gov/gene) — informações complementares dos genes marcadores, incluindo identificadores e localização cromossômica

4.2.4 Ambiente de desenvolvimento:

- **Python 3** com gerenciamento de dependências por virtualenv, compatível com sistemas macOS e Linux. O código-fonte da pipeline está organizado em módulos sequenciais numerados, cobrindo as etapas de pré-processamento, extração de features, treinamento, avaliação e predição individual de proteínas.

5 RESULTADOS PRELIMINARES

Esta seção apresenta os resultados obtidos durante o desenvolvimento do trabalho, organizados em dois conjuntos. O primeiro avalia o impacto do tamanho do vetor de projeção no desempenho dos modelos supervisionados, com grupo controle composto por três níveis de dificuldade discriminativa. O segundo apresenta a validação externa com proteínas não incluídas no treinamento. Todos os experimentos foram conduzidos com validação cruzada estratificada de 10 folds com otimização de hiperparâmetros via GridSearchCV.

5.1 EXPERIMENTO - GRUPO CONTROLE

Os experimentos foram conduzidos com 111 sequências positivas e 112 sequências negativas, totalizando 223 amostras. O grupo controle negativo foi composto por três subgrupos de dificuldade discriminativa crescente: proteínas housekeeping com funções em metabolismo energético e estrutura celular, proteínas imunes sem associação genética com psoríase, e proteínas de marcadores genéticos confirmados de doença de Crohn (NOD2, ATG16L1, IRGM) e artrite reumatoide (CTLA4, PADI4, PTPN22, TRAF1) — doenças com sobreposição genética com a psoríase segundo Tsoi et al. (2012). Foram testados quatro tamanhos de vetor de projeção — 300, 400, 500 e 1.000 componentes — com os seis modelos supervisionados.

Quadro 1 — Desempenho dos classificadores com N=300

Modelo	Acurácia	F1 Score	Precisão	Sensibilidade	Especificidade	ROC-AUC	MCC
Random Forest	93,3% ±4,6%	93,0% ±4,8%	96,3% ±4,5%	90,2% ±7,4%	96,4% ±4,5%	98,9% ±0,9%	87,0% ±9,0%
SVM	92,9% ±4,5%	92,5% ±4,9%	96,6% ±5,4%	89,2% ±7,9%	96,4% ±6,0%	98,5% ±1,7%	86,4% ±8,6%
Regressão Logística	93,7% ±4,5%	93,8% ±4,6%	92,4% ±5,5%	95,5% ±6,0%	91,9% ±6,4%	97,6% ±2,1%	87,8% ±8,9%
Gradient Boosting	88,3% ±6,2%	88,7% ±5,6%	86,7% ±6,7%	91,0% ±5,8%	85,6% ±8,4%	96,6% ±2,3%	76,9% ±12,2%

kNN	81,2% ±8,4%	83,9% ±6,5%	74,6% ±8,6%	96,4% ±4,4%	66,1% ±14,7%	89,6% ±4,2%	65,7% ±14,9%
Naive Bayes	70,4% ±12,3%	65,2% ±15,3%	77,1% ±14,6%	57,8% ±17,7%	82,8% ±11,9%	73,2% ±15,8%	42,5% ±24,6%

Fonte: Elaborado pelos autores (2026).

Quadro 2 — Desempenho dos classificadores com N=400

Modelo	Acurácia	F1 Score	Precisão	Sensibilidade	Especificidade	ROC-AUC	MCC
SVM	92,9% ±4,0%	92,3% ±4,9%	96,6% ±4,2%	89,2% ±9,8%	96,4% ±4,4%	98,5% ±1,5%	86,5% ±7,3%
Regressão Logística	93,3% ±4,6%	93,4% ±4,6%	91,6% ±5,1%	95,5% ±6,0%	91,0% ±5,8%	97,1% ±3,0%	86,9% ±9,0%
Random Forest	91,4% ±4,8%	91,4% ±4,8%	91,3% ±5,3%	91,9% ±6,4%	90,9% ±5,7%	98,1% ±1,9%	83,1% ±9,5%
Gradient Boosting	86,6% ±4,0%	86,9% ±4,1%	85,0% ±7,3%	90,1% ±8,6%	83,1% ±10,1%	95,7% ±3,0%	74,4% ±7,5%
kNN	82,5% ±8,4%	84,9% ±6,8%	76,4% ±9,6%	96,4% ±6,0%	68,7% ±15,4%	90,1% ±4,6%	68,3% ±14,8%
Naive Bayes	70,4% ±12,3%	65,0% ±15,2%	77,9% ±14,9%	56,9% ±17,1%	83,7% ±12,1%	73,5% ±14,3%	42,6% ±24,7%

Fonte: Elaborado pelos autores (2026).

Quadro 3 — Desempenho dos classificadores com N=500

Modelo	Acurácia	F1 Score	Precisão	Sensibilidade	Especificidade	ROC-AUC	MCC
SVM	93,7% ±3,6%	93,3% ±4,1%	97,4% ±3,9%	90,1% ±7,6%	97,3% ±4,1%	99,0% ±1,2%	88,1% ±6,6%
Regressão Logística	93,7% ±4,5%	93,7% ±4,8%	92,3% ±4,4%	95,5% ±7,3%	91,9% ±4,9%	98,7% ±1,6%	87,8% ±9,0%
Random Forest	92,4% ±4,0%	92,4% ±4,0%	92,6% ±6,5%	92,8% ±6,8%	91,8% ±7,6%	99,0% ±1,5%	85,3% ±7,9%

Gradient Boosting	86,5% ±5,1%	86,7% ±5,1%	84,9% ±5,5%	89,2% ±7,9%	83,9% ±6,9%	96,3% ±1,8%	73,5% ±10,1%
kNN	82,5% ±7,4%	85,2% ±5,5%	75,1% ±7,9%	99,1% ±2,7%	66,1% ±14,2%	91,4% ±5,2%	69,2% ±12,1%
Naive Bayes	70,4% ±11,8%	64,9% ±14,6%	78,2% ±14,4%	56,9% ±17,1%	83,7% ±12,1%	74,6% ±14,5%	42,8% ±23,7%

Fonte: Elaborado pelos autores (2026).

Quadro 4 — Desempenho dos classificadores com N=1.000

Modelo	Acurácia	F1 Score	Precisão	Sensibilidade	Especificidade	ROC-AUC	MCC
Regressão Logística	97,4% ±2,9%	97,3% ±3,2%	97,6% ±3,7%	97,3% ±5,8%	97,3% ±4,1%	99,8% ±0,3%	95,0% ±5,5%
SVM	95,1% ±3,1%	94,7% ±3,5%	98,4% ±3,2%	91,8% ±7,6%	98,2% ±3,6%	99,4% ±0,7%	90,7% ±5,8%
Random Forest	95,1% ±2,5%	94,9% ±2,5%	97,6% ±5,0%	92,8% ±5,4%	97,3% ±5,8%	99,3% ±1,0%	90,6% ±4,5%
Gradient Boosting	87,0% ±7,9%	87,8% ±7,0%	83,7% ±8,9%	92,8% ±6,8%	81,2% ±11,7%	95,5% ±3,1%	74,9% ±15,5%
kNN	81,2% ±5,9%	84,3% ±4,2%	73,1% ±6,2%	100,0% ±0,0%	62,5% ±11,7%	89,5% ±5,4%	67,5% ±9,3%
Naive Bayes	72,2% ±11,4%	66,2% ±14,8%	82,1% ±14,2%	56,9% ±17,1%	87,3% ±10,9%	78,1% ±14,8%	47,0% ±22,7%

Fonte: Elaborado pelos autores (2026).

5.2 EXPERIMENTO - VALIDAÇÃO EXTERNA

Com o modelo treinado na configuração de N=1.000 — a de melhor desempenho geral —, foi conduzida validação externa com cinco proteínas não incluídas no conjunto de treinamento, representando quatro categorias distintas: proteína negativa treinada, proteína negativa não treinada, proteína positiva treinada e proteínas positivas não treinadas de vias funcionalmente distintas.

Quadro 5 — Resultados da validação externa

Proteína	Categoria	Esperado	LR	SVM	RF	GB	NB	kNN
INS	Negativa treinada	Negativo	✓ 99,0%	✓ 99,6%	✓ 89,5%	✓ 100,0%	✓ 100,0%	✓ 100,0%
PTPN22	Negativa não treinada	Negativo	✓ 93,4%	✓ 99,6%	✓ 84,0%	✓ 100,0%	✓ 100,0%	✓ 66,7%
IL12B	Positiva treinada	Positivo	✓ 99,7%	✓ 100,0%	✓ 93,5%	✓ 100,0%	✓ 100,0%	✓ 100,0%
CARD14	Positiva não treinada — epitelial	Positivo	✗ 70,5%	✗ 51,2%	~ 52,5%	✗ 91,1%	✗ 100,0%	✓ 100,0%
RUNX3	Positiva não treinada — imune sistêmica	Positivo	✓ 67,6%	✓ 90,3%	✗ 51,0%	✗ 100,0%	✗ 100,0%	✓ 100,0%

Fonte: Elaborado pelos autores (2026).

✓ indica classificação correta, ✗ indica classificação incorreta e ~ indica resultado limítrofe. Os valores indicam a confiança do modelo na classe predita. Para predições corretas (✓, ~), reflete a probabilidade da classe esperada; para predições incorretas (✗), reflete a probabilidade da classe oposta.

5.3 SÍNTESE DOS RESULTADOS

Os resultados preliminares evidenciam três padrões consistentes ao longo dos experimentos.

O primeiro padrão é a relação entre o tamanho do vetor de projeção e o desempenho dos modelos: N=1.000 produziu os melhores resultados para os três modelos principais — Regressão Logística, SVM e Random Forest —, com ganhos progressivos de ROC-AUC à medida que o número de componentes aumentou de 300 para 1.000. Este comportamento é consistente com a expectativa teórica de que vetores maiores preservam mais informação das frequências de k-mers originais. A

Regressão Logística com N=1.000 obteve o melhor resultado geral, com ROC-AUC de 99,8% e MCC de 95,0%, seguida de SVM e Random Forest com resultados equivalentes entre si.

O segundo padrão é a separação clara entre os modelos principais e os modelos secundários em todas as configurações testadas: Regressão Logística, SVM e Random Forest apresentaram consistentemente ROC-AUC acima de 97% e MCC acima de 83%, enquanto Gradient Boosting, kNN e Naive Bayes apresentaram desempenho inferior em todas as métricas. O kNN destacou-se negativamente pela combinação de sensibilidade muito elevada — chegando a 100% em N=1.000 — com especificidade baixa, comportamento característico de um classificador que tende a classificar a maioria das amostras como positivas.

O terceiro padrão, revelado pela validação externa, é a distinção entre dois tipos de marcadores não treinados: RUNX3 — proteína imune sistêmica reguladora de células T, confirmada como newly identified loci por Tsoi et al. (2012) — foi corretamente identificada como positiva pela Regressão Logística com 67,6% de confiança e pelo SVM com 90,3%, enquanto CARD14 — marcador de psoríase expresso predominantemente em queratinócitos — não foi reconhecida pela maioria dos modelos. Este resultado delimita o escopo de generalização da abordagem: o modelo demonstra capacidade de identificar proteínas imunes sistêmicas da mesma família funcional dos marcadores de treinamento, com menor generalização para marcadores de vias distintas como a sinalização epitelial em queratinócitos.

6 DISCUSSÃO E CONCLUSÃO

O presente trabalho desenvolveu e avaliou uma pipeline in silico para classificação de proteínas associadas à psoríase, baseada em representação de sequências de aminoácidos por k-mers e modelos supervisionados de aprendizado de máquina. A pipeline demonstrou capacidade de distinguir proteínas dos marcadores genéticos confirmados da doença de proteínas funcionalmente não relacionadas, com desempenho quantificado por métricas consolidadas na literatura de classificação proteica — acurácia, F1-score, ROC-AUC e MCC — avaliadas por validação cruzada estratificada de 10 folds com otimização de hiperparâmetros via GridSearchCV.

Do ponto de vista técnico, os resultados obtidos indicam que a abordagem por k-mers é eficaz para reconhecer proteínas similares às proteínas de psoríase conhecidas, incluindo homólogos de múltiplos organismos. Os três modelos principais — Regressão Logística, SVM e Random Forest — apresentaram desempenho consistentemente elevado em todas as configurações testadas, com ROC-AUC acima de 97% e MCC acima de 83% para vetores de 300 a 1.000 componentes. A Regressão Logística com N=1.000 obteve o melhor resultado geral, com ROC-AUC de 99,8% e MCC de 95,0%, confirmando que vetores de maior dimensionalidade preservam mais informação discriminativa das frequências de k-mers. O Gradient Boosting apresentou desempenho intermediário consistente, enquanto kNN e Naive Bayes demonstraram limitações estruturais para este problema — o primeiro pela tendência de classificar a maioria das amostras como positivas em espaços de alta dimensionalidade, e o segundo pela suposição de independência entre features incompatível com a natureza correlacionada dos k-mers.

A validação externa com proteínas não incluídas no treinamento revelou um padrão biologicamente coerente e interpretável. Proteínas treinadas e negativos não treinados foram corretamente classificados pelos modelos principais com alta confiança. Entre os marcadores positivos não treinados, RUNX3 — proteína imune sistêmica reguladora de células T, confirmada como newly identified loci por Tsoi et al. (2012) — foi corretamente identificada pela Regressão Logística com 67,6% de confiança e pelo SVM com 90,3%, demonstrando capacidade de generalização para

proteínas da mesma família funcional dos marcadores de treinamento. Em contraste, CARD14 — marcador de psoríase expresso predominantemente em queratinócitos — não foi reconhecida pela maioria dos modelos, delimitando o escopo atual da abordagem: o modelo generaliza para proteínas imunes sistêmicas similares às proteínas de treinamento, com menor capacidade de reconhecimento de marcadores de vias funcionalmente distintas como a sinalização epitelial.

Do ponto de vista científico, o produto desta pesquisa contribui para o campo da bioinformática computacional aplicada à medicina de precisão ao estabelecer uma prova de conceito para classificação proteica de marcadores de psoríase por k-mers e delimitar empiricamente o escopo de generalização da abordagem. Diferentemente dos métodos existentes — que dependem de imagens clínicas, avaliação presencial ou genotipagem individual de pacientes —, a abordagem proposta opera exclusivamente sobre sequências proteicas obtidas de bancos de dados públicos, sem necessidade de amostras biológicas de pacientes, ampliando o potencial de aplicação para triagem proteômica in silico em larga escala.

Para a sociedade, os resultados deste trabalho contribuem indiretamente para o desenvolvimento futuro de ferramentas de apoio ao diagnóstico de psoríase mais acessíveis, especialmente relevantes no contexto da atenção primária brasileira, onde a escassez de dermatologistas especializados limita o acesso ao diagnóstico preciso — problema identificado por Cipriano et al. (2025) como uma das principais motivações para o desenvolvimento de modelos computacionais de apoio ao diagnóstico dermatológico no SUS.

6.1 Trabalhos Futuros

O presente trabalho estabelece a base metodológica para investigações a serem conduzidas na continuidade do projeto, com foco em três direções principais.

A primeira direção é a investigação do impacto do parâmetro k na capacidade representacional da pipeline. Os experimentos conduzidos neste trabalho utilizaram exclusivamente k=3, seguindo a recomendação de Guo et al. (2021). A avaliação de valores alternativos — em particular k=2 e k=4 — permitirá verificar se vocabulários

menores ou maiores de k-mers produzem representações mais discriminativas para o problema específico de classificação de proteínas de psoríase, contribuindo para a fundamentação empírica da escolha metodológica.

A segunda direção é o refinamento dos modelos por meio de fine-tuning mais extensivo dos hiperparâmetros, explorando espaços de busca mais amplos do que os utilizados no GridSearchCV inicial, bem como a avaliação de arquiteturas complementares como redes neurais — cuja aplicação a datasets maiores pode revelar padrões não capturados pelos modelos clássicos testados.

A terceira direção, e potencialmente a de maior impacto científico, é a aplicação da pipeline treinada à análise de um proteoma humano completo — testando a capacidade do modelo de identificar, entre as aproximadamente 20.000 proteínas do proteoma, candidatos a biomarcadores de psoríase não previamente descritos. Esta aplicação representa a transição da prova de conceito para um cenário de uso real, aproximando a abordagem do contexto clínico e de descoberta de biomarcadores.

REFERÊNCIAS

CIPRIANO, Raiza Brito et al. Inteligência artificial para diagnóstico de doenças dermatológicas eritemato-descamativas: contribuições tecnológicas para a atenção primária. **Anais Brasileiros de Dermatologia**, v. 100, n. 5, p. 501169, 2025. Disponível em: https://doi.org/10.1016/j.abd.2025.501169. Acesso em: 07 jun. 2026.

DAND, Nick; STUART, Philip E.; TSOI, Lam C. et al. GWAS meta-analysis of psoriasis identifies new susceptibility alleles impacting disease mechanisms and therapeutic targets. **Nature Communications**, v. 16, 2025. Disponível em: https://www.nature.com/articles/s41467-025-56719-8. Acesso em: 02 jun. 2026.

GANATRA, Darshini et al. Combining clinical, genetic and protein markers using machine learning models discriminates psoriatic arthritis from psoriasis. **Arthritis Research & Therapy**, v. 27, 2025. Disponível em: https://pubmed.ncbi.nlm.nih.gov/40400532/. Acesso em: 08 jun. 2026.

GUO, Yuxin et al. Prediction of hormone-binding proteins based on k-mer feature representation and naive Bayes. **Frontiers in Genetics**, v. 12, p. 797641, 2021. Disponível em: https://www.frontiersin.org/journals/genetics/articles/10.3389/fgene.2021.797641. Acesso em: 08 jun. 2026.

HARDEN, Jillian L.; KRUEGER, James G.; BOWCOCK, Anne M. The immunogenetics of psoriasis: a comprehensive review. **Journal of Autoimmunity**, v. 64, p. 66-73, 2015. Disponível em: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4628849/. Acesso em: 08 jun. 2026.

HUANG, Kai et al. Artificial intelligence-based psoriasis severity assessment: real-world study and application. **Journal of Medical Internet Research**, v. 25, p. e44932, 2023. Disponível em: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10131673/. Acesso em: 08 jun. 2026.

LI, Yonghong; BEGOVICH, Ann B. Unraveling the genetics of complex diseases: susceptibility genes for rheumatoid arthritis and psoriasis. **Seminars in Immunology**, v. 21, n. 6, p. 318-327, dez. 2009. Disponível em: https://pubmed.ncbi.nlm.nih.gov/19446472/. Acesso em: 16 mai. 2026.

MCMULLEN, Eric P. et al. Predicting psoriasis severity using machine learning: a systematic review. **Clinical and Experimental Dermatology**, v. 50, n. 3, p. 520-528, 2025. Disponível em: https://academic.oup.com/ced/article/50/3/520/7738978. Acesso em: 08 jun. 2026.

RAN, Delin; CAI, Minglong; ZHANG, Xuejun. Genetics of psoriasis: a basis for precision medicine. **Precision Clinical Medicine**, v. 2, n. 2, p. 120-130, jun. 2019. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC9026189/. Acesso em: 08 jun. 2026.

TSIANOS, Epameinondas V.; KATSANOS, Konstantinos H.; TSIANOS, Vasileios E. Role of genetics in the diagnosis and prognosis of Crohn's disease. **World Journal of Gastroenterology**, v. 18, n. 29, p. 3834-3844, 2012. Disponível

em: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3257437/. Acesso em: 08 jun. 2026.

TSOI, Lam C. et al. Identification of 15 new psoriasis susceptibility loci highlights the role of innate immunity. **Nature Genetics**, v. 44, n. 12, p. 1341-1348, dez. 2012. Disponível em: https://www.nature.com/articles/ng.2467. Acesso em: 04 mai. 2026.

TSOI, Lam C. et al. Enhanced meta-analysis and replication studies identify five new psoriasis susceptibility loci. **Nature Communications**, v. 6, p. 7001, 2015. Disponível em: https://www.nature.com/articles/ncomms8001. Acesso em: 04 mai. 2026.

TSOI, Lam C. et al. Large scale meta-analysis characterizes genetic architecture for common psoriasis associated variants. **Nature Communications**, v. 8, p. 15382, 2017. Disponível em: https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5458077/. Acesso em: 04 mai. 2026.

YANG, Zhiyuan et al. A convolutional neural network trained with dermoscopic images of psoriasis performed on par with 230 dermatologists. **Computers in Biology and Medicine**, v. 139, p. 104924, 2021. Disponível em: https://pubmed.ncbi.nlm.nih.gov/34688173/. Acesso em: 16 mai. 2026.

YIN, Xianyong et al. A weighted polygenic risk score using 14 known susceptibility variants to estimate risk and age onset of psoriasis in Han Chinese. **PLOS ONE**, v. 10, n. 5, p. e0125369, 2015. Disponível em: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0125369. Acesso em: 16 mai. 2026.